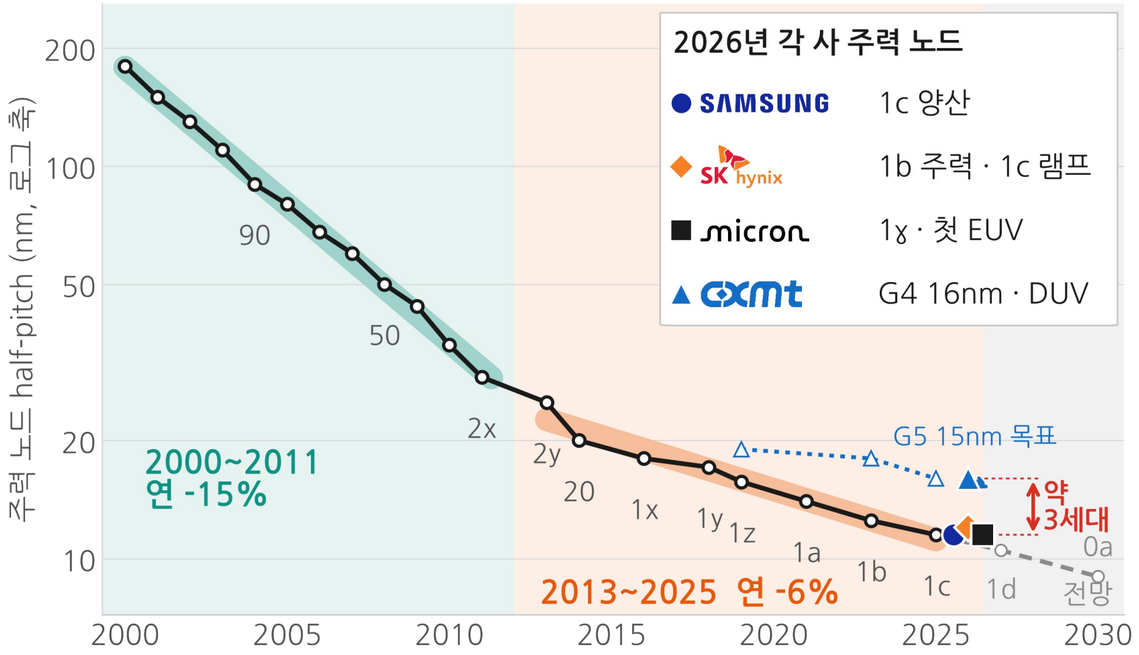
DRAM 은 Shrink 장벽에 막혀 후발 주자의 추격을 받고 있지만 , AI 추론의 병목이 연산에서 메모리로 옮겨 오며 차별화의 기회가 열리고 있다

1 위기 : Shrink 장벽과 후발 주자의 추격



-15% → -6%
연간 노드 축소 속도
2000~11 → 2013~25

1 년 → 1.6 년
새 노드가 나오는 간격
2000~11 → 2013~25

CXMT 93%
2026 말 캐파 , Micron 대비
35 만 vs 37.5 만 wpm

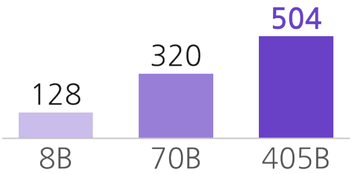
2 기회 : AI 추론의 병목은 연산이 아닌 메모리

알고리즘
모델 · 문맥 · 추론 SW

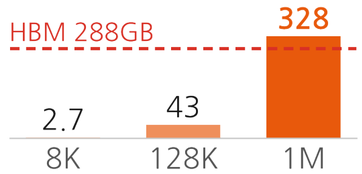
더 많이 요구 · 더 크게 허용

메모리
고용량 · 고대역폭

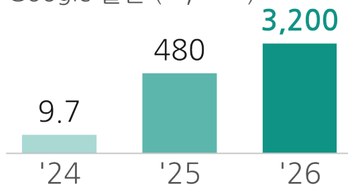
더 큰 모델
KV / 토큰 (KiB)



더 긴 문맥
요청 1건 KV (GB)



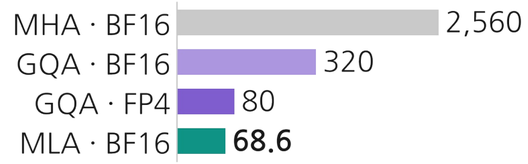
더 많은 토큰
Google 월간 (조, 로그)



메모리 총수요 산술
KV/ 토큰 × 월간 토큰 → 상주량 (가정 : HBM 체류 60 초 ~5 분)

320 KiB
KV / 토큰 (70B)
×
3,200 조
Google 월간 토큰
=
≈1 ZB
월간 KV 생성
→
8 만 ~42 만 개
HBM 288GB 가속기분

알고리즘이 줄인다 (KiB / 토큰)



Paged 낭비 70%→4% · Prefix 재사용 86%

메모리는 바로 늘릴 수 없다



팹 건설 · 장비 · HBM 웨이퍼 소모

2026
부족 1~2%

2H27
신규 팹 램프

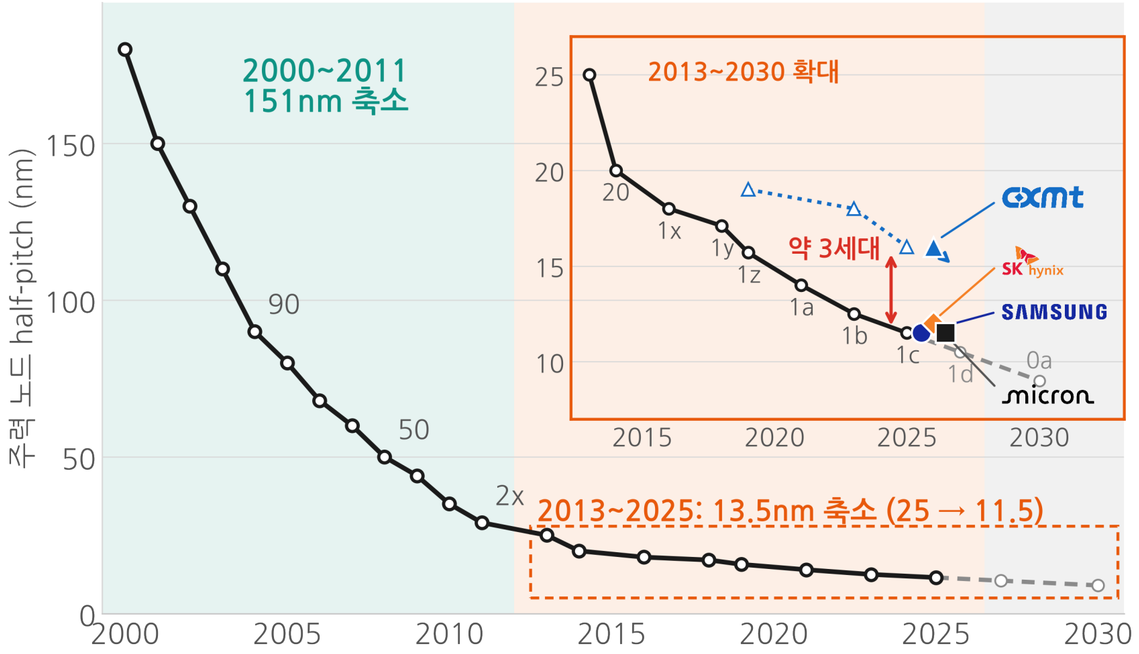
2028
실질 출하

현실 Shrink 만으로는 격차를 지킬 수 없다 . 차별화는 AI 추론의 메모리 병목에서 찾는다

출처 : 노드 : ITRS · TechInsights · 각 사 발표 (선두 주력 양산 근사) · 2026 위치 : Fab Tracker Q2'26 · Digitimes · SemiAnalysis / KV: Llama 3.1 · DeepSeek-V3 설정 산식 · 토큰 : Google I/O · Paged: SOSP'23 · 공급 : TrendForce 2026-07 · 산술은 가정 의존 · 부품은 3D 렌더

DRAM 은 Shrink 장벽에 막혀 후발 주자의 추격을 받고 있지만 , AI 추론의 병목이 연산에서 메모리로 옮겨 오며 차별화의 기회가 열리고 있다

1 위기 : Shrink 장벽과 후발 주자의 추격

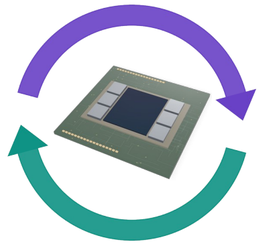


-15% → -6%
연간 노드 축소 속도
2000~11 → 2013~25

1 년 → 1.6 년
새 노드가 나오는 간격
2000~11 → 2013~25

cxmt 93%
2026 말 캐파 , Micron 대비
35 만 vs 37.5 만 wpm

2 기회 : AI 추론의 병목은 연산이 아닌 메모리



알고리즘이 메모리에 요구하는 것

더 큰 모델	KV/ 토큰 128 → 504 KiB
더 긴 문맥	요청 1 건 2.7 → 328 GB
더 많은 토큰	Google 월 9.7 조 → 3,200 조

320 KiB × 월 3,200 조 토큰 ≈ 월 1 ZB KV
HBM 가속기 8 만 ~42 만 개 분량
산술 · 가정 : 288GB 가속기 , HBM 체류 60 초 ~5 분

줄이는 힘보다 늘리는 힘이 크다 (2024~2026, 요인별 배수)



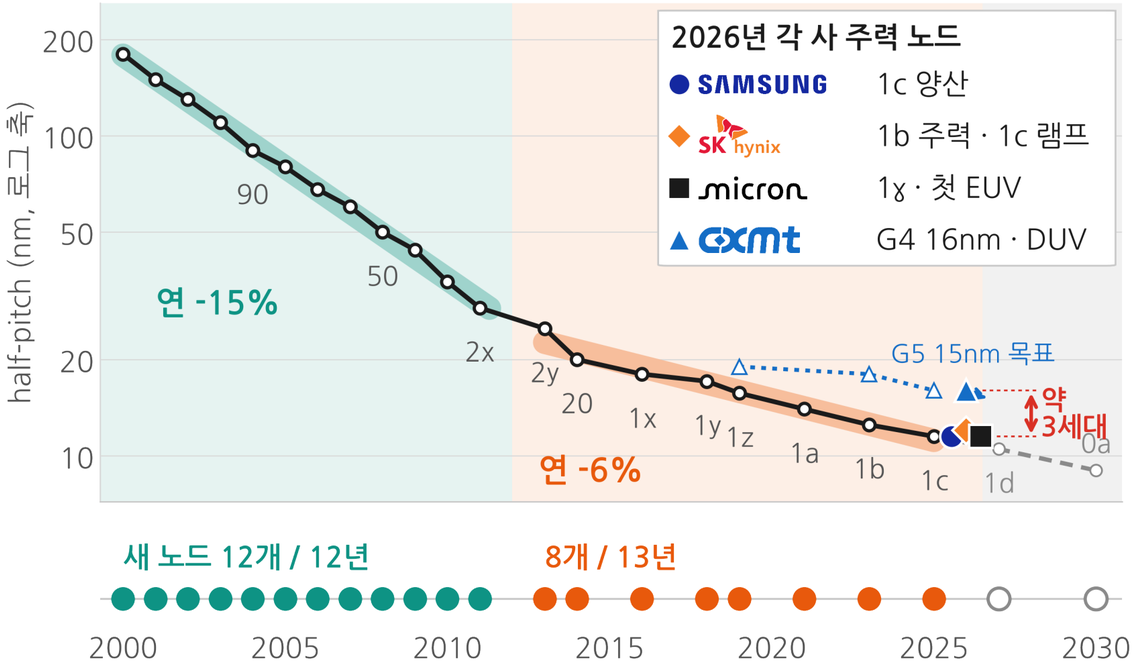
공급 한계 2026 충족률 -1~-2%, 신규 팹 실질 기여는 2028 년

현실 Shrink 만으로는 격차를 지킬 수 없다 . 차별화는 AI 추론의 메모리 병목에서 찾는다

출처 : 노드 : ITRS · TechInsights · 각 사 발표 (선두 주력 양산 근사) · 2026 위치 : Fab Tracker Q2'26 · Digitimes · SemiAnalysis / KV: Llama 3.1 · DeepSeek-V3 설정 산식 · 토큰 : Google I/O · Paged: SOSP'23 · 공급 : TrendForce 2026-07 · 산술은 가정 의존 · 부품은 3D 렌더 · 배수는 요인별 (곱하지 않음)

DRAM 은 Shrink 장벽에 막혀 후발 주자의 추격을 받고 있지만 , AI 추론의 병목이 연산에서 메모리로 옮겨 오며 차별화의 기회가 열리고 있다

1 위기 : Shrink 장벽과 후발 주자의 추격



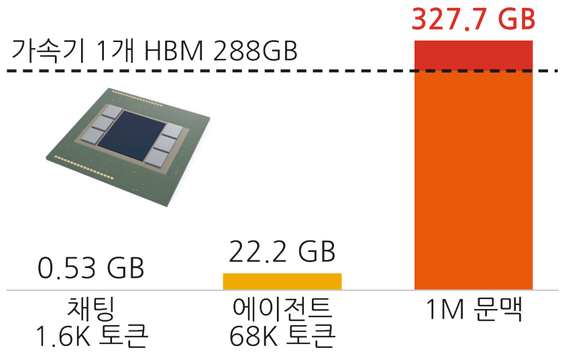
-15% → -6%
연간 노드 축소 속도
2000~11 → 2013~25

1 년 → 1.6 년
새 노드가 나오는 간격
2000~11 → 2013~25

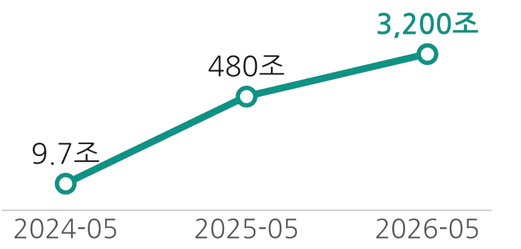
CXMT 93%
2026 말 캐파 , Micron 대비
35 만 vs 37.5 만 wpm

2 기회 : AI 추론의 병목은 연산이 아닌 메모리

요청 1건의 KV (70B급, BF16)

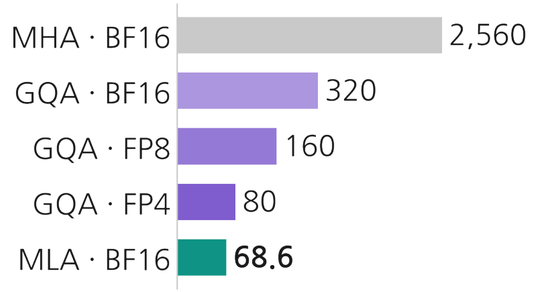


Google 월간 처리 토큰 (로그 축)



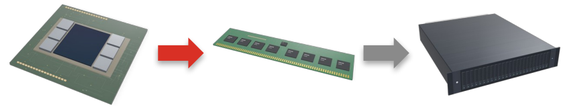
× 320 KiB/ 토큰 = 월 ≈ 1 ZB KV

알고리즘이 줄인다 (KiB / 토큰)



Paged 낭비 70%→4% · Prefix 재사용 86%

넘치면 아래 계층으로 , 공급은 2028 년



2026 부족 1~2%
2H27 신규 팹 램프
2028 실질 출하

현실 **Shrink 만으로는 격차를 지킬 수 없다 . 차별화는 AI 추론의 메모리 병목에서 찾는다**

출처 : 노드 : ITRS · TechInsights · 각 사 발표 (선두 주력 양산 근사) · 2026 위치 : Fab Tracker Q2'26 · Digitimes · SemiAnalysis / KV: Llama 3.1 · DeepSeek-V3 설정 산식 · 토큰 : Google I/O · Paged: SOSP'23 · 공급 : TrendForce 2026-07 · 산술은 가정 의존 · 부품은 3D 렌더 · KV 계층화 : Google Next '26